

基于多维度人工评估的中译英机器翻译质量对比研究——以 DeepL、ChatGPT、Gemini 和 Claude 为例

摘要

本研究选取 DeepL、ChatGPT (GPT-4o)、Google Gemini 和 Claude 四种较常见的机器翻译系统，围绕口语体、新闻体、学术体、文学体和文化负载型五类文本，共 50 条中文语料开展中译英翻译测试，总计得到 200 条译文。研究采用五维度人工评估框架，从准确性、流畅性、风格匹配、术语准确性和文化适应性五个方面对译文进行评分。结果显示，三种大语言模型系统整体表现均优于传统神经机器翻译系统 DeepL，其中 Claude 平均得分最高（4.79），GPT 和 Gemini 次之，DeepL 相对较低（4.18）。不同文本类型对翻译质量影响较大：学术类文本中各系统差距较小，而文化负载类文本最能拉开差距。就评估维度来看，流畅性上的差异已经比较有限，真正体现系统差别的主要是文化适应性和术语准确性。此外，各系统在不同文本类型上各有优势，没有任何一种系统在所有类型中都保持领先。研究结果可为翻译实践中的工具选择提供参考，也可为大语言模型背景下的机器翻译质量评估研究补充一定的实证材料。

关键词：机器翻译；翻译质量评估；大语言模型；中译英；DeepL；ChatGPT；Gemini；Claude

Abstract

This study evaluates the Chinese-to-English translation quality of four mainstream machine translation systems – DeepL, ChatGPT (GPT-4o), Google Gemini, and Claude – using a multi-dimensional human evaluation framework. Fifty Chinese source sentences across five text types (colloquial, news, academic, literary, and culture-loaded) were translated by each system, yielding 200 translation outputs. Each output was scored on five dimensions: accuracy, fluency, style matching, terminology accuracy, and cultural adaptation, using a 1–5 Likert scale. Key findings include: (1) the three LLM-based systems (Claude 4.79, GPT 4.71, Gemini 4.67) significantly outperformed the traditional NMT system DeepL (4.18); (2) text type is the strongest moderating variable, with academic texts showing convergence and culture-loaded texts showing the greatest divergence; (3) fluency has reached a ceiling across all systems, while cultural adaptation and terminology accuracy remain the key differentiating dimensions; and (4) no single system dominates across all text types. This study provides empirical evidence for translation practitioners in tool selection and contributes to the literature on MT quality assessment in the LLM era.

Keywords: machine translation; translation quality assessment; large language models; Chinese-to-English; DeepL; ChatGPT; Gemini; Claude

第一章 引言

1.1 研究背景

过去十年间，机器翻译技术发展较快。2014 年，基于编码器-解码器结构的神经机器翻译（Neural Machine Translation, NMT）模型出现，机器翻译逐渐从统计方法转向深度学习方法。2017 年 Transformer 架构提出后，翻译质量又有了明显提升。DeepL 就是这一阶段较有代表性的专用 NMT 系统之一，在翻译实践中使用较多。

2022 年底 ChatGPT 发布后，大语言模型（Large Language Model, LLM）迅速受到广泛关注。虽然翻译并不是这类模型唯一的核心任务，但它们在翻译方面的表现引起了很多讨论。随后，Google 推出 Gemini，Anthropic 推出 Claude，这些通用大模型在翻译任务上的能力进一步受到重视。与传统 NMT 相比，LLM 在世界知识储备、上下文理解和语言生成灵活性等方面表现出一定优势，也使机器翻译工具之间的竞争格局发生了变化。

在中国的实际应用场景中，中译英翻译需求一直较大，比如学术论文发表、国际新闻传播、文学作品外译以及跨文化交流等领域都需要高质量的英文译文。相比之下，针对新一代 LLM 系统中译英任务上的系统性评估研究还不算多，尤其是同时纳入多种文本类型、多个评估维度的对比研究仍比较有限。因此，有必要对当前主流系统进行较为具体的比较分析。

1.2 研究问题

本研究主要围绕以下三个问题展开：

RQ1: DeepL、ChatGPT、Gemini 和 Claude 四个系统中译英翻译中的整体质量如何排序？

RQ2: 在口语体、新闻体、学术体、文学体和文化负载型五种文本类型下，各系统的表现是否存在明显差异？哪一种文本类型最能区分系统质量？

RQ3: 从准确性、流畅性、风格匹配、术语准确性和文化适应性五个维度来看，各系统分别有哪些优势与不足？

1.3 研究意义

本研究的意义主要体现在以下三个方面。

第一，在理论层面，当前关于大语言模型时代中译英机器翻译质量的对比研究仍然不算充分，尤其是多维度人工评估的相关研究还比较少。本文希望在这一方面补充一些实证材料。

第二，在实践层面，不同翻译任务对译文的要求并不完全相同。通过对不同文本类型和不同系统表现的比较，可以为翻译从业者、语言服务机构以及外语教学中的工具选择提供参考。

第三，在方法层面，本文构建了一个包含文化适应性的五维度评估框架，试图比单纯依赖准确性和流畅性的评估方式更全面一些，这也可以为类似研究提供一定借鉴。

1.4 论文结构

全文共分为六章。第一章为引言，介绍研究背景、研究问题和研究意义。第二章为文献综述，回顾机器翻译的发展过程、评估方法以及相关研究现状。第三章为研究方法，说明语料来源、系统配置与评估框架。第四章为研究结果，展示主要数据与案例。第五章为讨论，对结果进行分析和解释。第六章为结论，总结主要发现，指出研究局限，并提出后续研究方向。

第二章 文献综述

2.1 机器翻译的发展历程

2.1.1 基于规则的机器翻译（1950s–1990s）

机器翻译最早可追溯到 1954 年乔治敦大学与 IBM 合作进行的俄英翻译实验。早期系统主要依赖人工编写的语法规则和双语词典，典型代表包括 1968 年的 SYSTRAN。这类基于规则的机器翻译（Rule-Based Machine Translation, RBMT）在特定领域中有一定效果，但在开放领域文本中往往受到规则覆盖范围有限的影响，翻译质量不够稳定。

2.1.2 统计机器翻译（1990s–2014）

Brown 等人（1990）提出统计机器翻译（Statistical Machine Translation, SMT）后，机器翻译进入了新的阶段。SMT 利用大规模平行语料库学习翻译概率，减少了对人工规则的依赖。2000 年代，基于短语的统计机器翻译逐渐成为主流，Google Translate 早期也采用过这一技术路线。不过，SMT 在处理长距离依赖和语序差异较大的语言对时仍存在较明显局限。

2.1.3 神经机器翻译（2014 至今）

Sutskever 等人（2014）提出基于编码器—解码器的序列到序列模型，标志着神经机器翻译时代的开始。随后，Bahdanau 等人（2015）引入注意力机制，使翻译质量得到进一步提升。2017 年 Vaswani 等人提出 Transformer 架构后，神经机器翻译进入快速发展阶段。当前多数主流翻译系统的底层架构都与 Transformer 有关。DeepL 通常被认为是这一阶段专用 NMT 系统中的代表之一。

2.1.4 大语言模型时代（2022 至今）

2022 年 11 月 ChatGPT 发布后，大语言模型的通用语言处理能力引起了广泛关注。翻译虽然只是其多项能力中的一种，但在实际使用中表现出较强竞争力。2023 年至 2024 年间，GPT-4、GPT-4o、Google Gemini 和 Anthropic Claude 等模型陆续推出，使机器翻译研究开始更多关注 LLM 与传统 NMT 之间的差异。这些模型通常以大规模多语言数据进行训练，在知识储备、推理能力和上下文理解方面具有新的特点。

2.2 四种翻译系统简介

DeepL: DeepL 由德国 DeepL GmbH 推出，是较有代表性的专用翻译系统。其优势通常体现在翻译速度较快、输出较稳定，在实际使用中拥有较高知名度。

ChatGPT（GPT-4o）: ChatGPT 是 OpenAI 开发的通用大语言模型。GPT-4o 作为其重要版本之一，具备较强的语言理解与生成能力，翻译是其应用场景之一。

Google Gemini: Gemini 由 Google DeepMind 开发。由于 Google 长期积累了机器翻译与多语言处理相关技术，Gemini 在翻译方面也具有较强潜力。

Claude: Claude 由 Anthropic 开发，较强调安全性与文本理解能力，在长文本处理和语言表达细致性方面受到关注。

2.3 机器翻译质量评估方法

2.3.1 自动评估指标

BLEU（Papineni et al., 2002）是最常见的机器翻译自动评估指标之一，主要通过计算机器译文与参考译文之间的 n-gram 重合度进行打分。此后又出现了 METEOR（Banerjee & Lavie, 2005）、TER（Snover et al., 2006）、COMET（Rei et al., 2020）等指标。

不过，自动评估指标也存在一些问题。首先，它们通常依赖参考译文，而翻译往往存在多种合理表达。其次，对于文化适应、语域匹配等较深层的翻译质量，自动指标不容易

准确反映。再者，在中英这类语序差异较大的语言对中，表层匹配程度与人工判断之间并不总是高度一致。

2.3.2 人工评估方法

人工评估目前仍然被普遍视为机器翻译质量评估中的重要方式。常见方法主要包括以下几类：

- （1）充分性与流畅性评估：分别考察译文是否完整传达原文信息，以及目标语表达是否自然通顺。
- （2）直接评估（Direct Assessment, DA）：由评估者在连续量表上对译文进行整体评分（Graham et al., 2013）。
- （3）MQM（Multidimensional Quality Metrics）：根据错误类型对翻译问题进行标注和分类（Lommel et al., 2014）。

本文采用的是五维度人工评估框架，在准确性和流畅性之外，增加了风格匹配、术语准确性和文化适应性，以便更全面地观察系统差异。

2.4 中译英机器翻译研究现状

近年来，中译英机器翻译质量评估研究逐步增多，但现有研究较多集中于新闻文本和学术文本，也较常依赖 BLEU 等自动指标。对口语体、文学体以及网络文化表达等文本类型的关注相对不足。

在 LLM 翻译研究方面，Jiao 等人（2023）对 ChatGPT 的翻译能力进行了初步评估，指出其在部分高资源语言对上已经接近商用 NMT 系统。Hendy 等人（2023）进一步对 GPT-4 的翻译表现进行了较系统研究。不过，同时纳入 Claude 和 Gemini，并专门聚焦中译英、多文本类型对比的研究仍然较少。

2.5 文本类型与翻译难度

Reiss（1971, 1976）的文本类型学认为，不同文本类型在功能和表达方式上存在差异，因此也会对翻译策略提出不同要求。本文在这一理论基础上，将测试语料划分为五类：

口语体：语言较口语化，情绪色彩明显，常包含隐含义和语用信息。

新闻体：注重信息完整、表达规范和语域正式。

学术体：强调逻辑性、术语准确性和表达严谨。

文学体：重视修辞、意象和文体风格。

文化负载型：包括成语、歇后语、网络流行语和文化典故等，对文化理解与转换能力要求较高。

Venuti（1995）提出的归化与异化策略，对文化负载内容的翻译具有较强参考意义。

2.6 研究空白与本研究定位

综合来看，目前相关研究仍存在以下不足：一是缺少覆盖多种文本类型的系统性比较；二是对 Claude 和 Gemini 等较新的 LLM 系统关注不够；三是在人工评估中，文化适应性这一维度往往没有被单独强调。本文希望通过多系统、多文本类型和多维度评估的方式，对这些问题作出补充。

第三章 研究方法

3.1 研究设计

本研究采用对比实验设计。4 个翻译系统、5 种文本类型、每类 10 条语料，共形成 200 条翻译输出。随后，基于五个评估维度对这些译文进行人工评分，并据此比较不同系统在整体表现、不同文本类型和不同评估维度上的差异。

3.2 语料选取

本研究共选取 50 条中文原文，按文本类型分为五类，每类 10 条。

口语体 (Colloquial, C01-C10)：选自日常对话、影视台词和社交媒体表达，包含反讽、催促、情绪表达等语用特点。

新闻体 (News, N01-N10)：选自主流新闻报道，涵盖科技、体育、文化和政治等内容。

学术体 (Academic, A01-A10)：选自自然语言处理、心理语言学和翻译学等领域的中文学术摘要。

文学体 (Literary, L01-L10)：选自鲁迅、朱自清、老舍、余华、张爱玲等作家作品。

文化负载型 (Cultural, K01-K10)：包括网络流行语、俗语、歇后语和成语等。

语料选取主要遵循三项原则：

第一，具有代表性，每类文本都尽量体现该类型常见的翻译难点；

第二，具备一定难度差异，以避免语料过于单一；

第三，保持可比性，长度尽量控制在一到两句之间。

表 1 列出了 50 条中文原文语料，正文中不再逐条重复。

表 1 中文原文语料表 (50 条)

ID	类型	中文原文	来源	难点标签
C01	口语	道歉有用的话，要警察干嘛？	《流星花园》台词页	反问；讽刺；口语语气
C02	口语	想哭的时候倒立，眼泪就流不出来了。	《流星花园》台词页	口语语气；惯用表达
C03	口语	我要我觉得，不要你觉得！	黄晓明综艺名场面	口语语气；口语节奏；强势语气
C04	口语	你有病啊，当然不是我的毛。	豆瓣《美人鱼》台词转录	口语语气；反问；粗直语域
C05	口语	你是不是傻？这么明显的事情你看不出来？	日常口语高频表达	反问；口语语气；粗直语域
C06	口语	滑雪就像人生一样不是吗……	豆瓣《国王在冬眠》台词	口语语气；反问；比喻
C07	口语	我真是谢谢你了，帮我帮成这样。	日常反讽口语	反讽；口语语气；语用含义
C08	口语	你看了几本上野千鹤子啊。	豆瓣《好东西》台词引用	口语语气；讽刺；文化人名
C09	口语	这一天天的，烦死了，我不演了，直接摊牌。	网络口语表达	网络口语；情绪语气；口语节奏
C10	口语	你别搁这闲聊了，快走吧！	赵本山小品对白	口语语气；口语

ID	类型	中文原文	来源	难点标签
				节奏；方言感
N01	新闻	生成式人工智能正在助力新闻进入“液态内容”阶段。	澎湃新闻	新闻语域；隐喻术语
N02	新闻	体重管理并非越瘦越好，而是将体重维持在健康、适宜的范围内。	人民日报	新闻语域；对比句式
N03	新闻	制造业是立国之本、强国之基。	新华社	新闻语域；正式文体；政治修辞
N04	新闻	北京时间 2 月 7 日凌晨，米兰冬奥会即将拉开帷幕。	人民日报海外版	新闻语域；时间表达；专有名词
N05	新闻	中文热是贴近中国、读懂中国的必然产物，更是中国国际影响力与日俱增的生动注脚。	人民日报	新闻语域；隐喻措辞；正式文体
N06	新闻	学中文、用中文，还只是世界友人了解中国、亲近中国浪潮里的一朵浪花。	人民日报	新闻语域；文学化比喻；正式文体
N07	新闻	当地时间 7 日，中国队组合王子菲/盛李豪在射击世界杯西班牙站 10 米气步枪混合团体决赛中逆转夺冠。	人民日报	新闻语域；信息密度；专有名词
N08	新闻	体育，承载着国家强盛、民族振兴的梦想。	人民日报	新闻语域；政治修辞；正式文体

ID	类型	中文原文	来源	难点标签
N09	新闻	我国智能机器人产业创新能力持续提升，应用场景不断拓展。	新华社	新闻语域；产业政策语言；正式文体
N10	新闻	从“跟跑”“并跑”再到“领跑”，中国用几十年时间走完了西方发达国家几百年走过的工业化历程。	新华社	新闻语域；隐喻措辞；历史叙事
A01	学术	文本倾向分析目的是确定文本所表达的态度或观点，近几年来已经成为信息检索和自然语言处理领域的一个热点问题。	CNKI 摘要	技术术语；学术摘要文体
A02	学术	阅读知觉广度通常指读者在阅读文本过程中每次注视能获得有用视觉信息的范围。	CNKI 摘要	技术术语；定义句式
A03	学术	采用眼动追踪技术探讨中文阅读中无关言语效应的影响机制。	CNKI 摘要	技术术语；学术摘要文体
A04	学术	虽然神经机器翻译模型使用大规模数据集进行训练能够改善翻译模型的表现，但是数据集中有关句子内容类别以及结构的信息并未得到充分利用。	CNKI 摘要	技术术语；长句复杂结构
A05	学术	议论文自动生成是自然语言生成中一项极具挑战性的任务。	CNKI 摘要	技术术语；学术摘要文体
A06	学术	自动词语简化是用简单、同等意义的词语替代句子中复杂词的过程，是文本简化中的一个重要研究方向。	CNKI 摘要	技术术语；定义句式
A07	学术	从 2017 年以来，自然语言处理中提出了“预训练+微调+师生学习”的新范式。	CNKI 摘要	技术术语；学术摘要文体

ID	类型	中文原文	来源	难点标签
A08	学术	机器翻译凭借着速度和效率上的优势，在语言服务行业发挥着越来越重要的作用。	CNKI 摘要	技术术语；学术摘要文体
A09	学术	自从机器翻译诞生以来，机器翻译能否取代人工翻译这一疑问一直存在。	CNKI 摘要	技术术语；学术摘要文体
A10	学术	由于机器翻译的机械性和随机性等短板，机器翻译无法完全取代人工翻译，机器翻译和人工翻译将长期共存并相互补充、相互促进。	CNKI 摘要	技术术语；长句复杂结构
L01	文学	我翻开历史一查，这历史每叶上都写著“仁义道德”几个字。	鲁迅《狂人日记》	文学修辞；古白话
L02	文学	仔细看了半夜，才从字缝里看出字来，满本都写著两个字，是“吃人”。	鲁迅《狂人日记》	文学修辞；隐喻；冲击力
L03	文学	我与父亲不相见已有二年馀了，我最不能忘记的是他的背影。	朱自清《背影》	文学修辞；情感表达
L04	文学	人是为活着本身而活着，不是为活着之外的任何事物所活着。	余华《活着》	文学修辞；哲理表达
L05	文学	这几天心里颇不宁静。	朱自清《荷塘月色》	文学修辞；情感表达
L06	文学	生命是一袭华美的袍，爬满了蚤子。	张爱玲《天才梦》	文学修辞；比喻；美学效果

ID	类型	中文原文	来源	难点标签
L07	文学	他没有什么模样，使他可爱的是脸上的精神。	老舍《骆驼祥子》	文学修辞；人物描写
L08	文学	他确乎有点象一棵树，坚壮，沉默，而又有生气。	老舍《骆驼祥子》	文学修辞；比喻；人物描写
L09	文学	过去的日子如轻烟，被微风吹散了，如薄雾，被初阳蒸融了。	朱自清《匆匆》	文学修辞；排比；意象
L10	文学	盼望着，盼望着，东风来了，春天的脚步近了。	朱自清《春》	文学修辞；反复；拟人
K01	文化	不作死就不会死。	人民网引用网络化表达	网络用语；文化负载
K02	文化	一清二白。	人民日报海外版	成语；文化负载
K03	文化	外甥打灯笼——照旧（舅）。	中国文化研究院	歇后语；谐音双关
K04	文化	我吃过的盐比你吃过的米还多。	人民日报海外版	俗语；文化负载
K05	文化	世界那么大，我想去看看。	中国网	网络流行语；文化负载
K06	文化	比如，大量数字、符号、字母混合使用，“3Q”表示谢谢你，“9494”表示就是就是，“emo”表示难过，“YYDS”意思是永远的神。	新华网	网络用语；缩写；文化负载

ID	类型	中文原文	来源	难点标签
K07	文化	破防。	新华社	网络用语；文化负载
K08	文化	我看不懂，但我大受震撼。	新华社	网络用语；文化负载
K09	文化	伤害性不高，侮辱性极强。	新华社	网络用语；修辞对仗
K10	文化	尸位素餐。	人民网	成语；文化负载

3.3 翻译系统配置

四个翻译系统的输出均于 2025 年 4 月 18 日统一采集，以尽量控制版本差异带来的影响。翻译时采用默认设置，不额外加入复杂提示词，直接输入中文原文并要求翻译为英文。

表 2 翻译系统配置

系统	版本/模型	采集方式
DeepL	网页版	直接粘贴原文
ChatGPT	GPT-4o	对话界面输入
Google Gemini	Gemini	对话界面输入
Claude	Claude	对话界面输入

3.4 评估框架

本文构建了一个五维度人工评估框架，每个维度均采用 1–5 分的李克特量表进行评分。

表 3 五维度评估框架

维度	定义	评分标准
Accuracy（准确性）	译文对原文语义的忠实程度	5=完全准确，1=严重失真
Fluency（流畅性）	译文在目标语中的自然通顺程度	5=完全自然，1=难以理解
Style（风格匹配）	译文与原文语域、文体的一致程度	5=完美匹配，1=严重偏离
Terminology（术语准确性）	专业术语、固定表达的翻译正确性	5=完全正确，1=严重错误
Cultural Adaptation（文化适应性）	文化负载内容的处理效果	5=完美适应，1=完全失败

综合得分（Avg_Score）取五个维度得分的算术平均值。

3.5 评估流程

评分由研究者本人完成。评估过程中，所有译文均逐条对照原文进行判断，并对主要评分理由进行了记录。全部评分结束后，又对数据进行了复核，以检查评分前后是否基本一致，同时确认统计结果和均分计算无误。

第四章 研究结果

4.1 各系统整体表现




Figure 1. Overall average translation quality scores of four MT systems.

表 4 四系统整体均分排名

排名	系统	均分
1	Claude	4.788
2	GPT	4.708
3	Gemini	4.672
4	DeepL	4.176

从整体均分来看，三种 LLM 系统的表现都明显好于 DeepL。Claude 以 4.788 排名第一，GPT 和 Gemini 分列第二、第三，三者均分都在 4.67 以上。相比之下，DeepL 的整体得分为 4.176，与三种 LLM 之间存在较明显差距。考虑到本研究采用的是 1–5 分量表，这一差距已经不算小，说明不同类型系统之间确实存在较为清晰的质量差别。

4.2 各文本类型下的系统表现




Figure 2. Average scores by text type and MT system.

表 5 各文本类型下四系统均分

文本类型	DeepL	GPT	Gemini	Claude	该类最佳
Colloquial	4.34	4.56	4.66	4.62	Gemini
News	4.22	4.80	4.34	4.86	Claude
Academic	4.38	5.00	4.98	4.92	GPT
Literary	4.42	4.78	4.68	4.68	GPT
Cultural	3.52	4.40	4.70	4.86	Claude

从文本类型来看，学术类文本整体得分最高。四个系统在这一类型中的得分都较高，GPT 甚至达到满分 5.00，说明学术文本在术语和句式较规范的情况下，对机器翻译系统相对友好。

文化负载类文本则最能体现系统之间的差异。DeepL 在该类文本中的均分仅为 3.52，而 Claude 达到 4.86，两者相差 1.34 分，是所有文本类型中差距最大的。这说明文化知识、语用理解和表达转换能力对翻译质量影响很大，而这恰恰是不同系统最容易拉开差距的地方。

另外，各系统的优势类型并不相同。GPT 在学术和文学文本中表现较好，Gemini 在口语类文本中得分最高，Claude 在新闻和文化负载类文本中最有优势。这表明实际使用中不能简单认为某一系统适用于所有任务，而应根据文本类型进行选择。

口语类文本中三种 LLM 之间分差很小，仅在 4.56 至 4.66 之间波动，说明在较常见的日常表达和口语语气处理上，各家大模型已经较为接近。相比之下，Gemini 在新闻类的表现低于其余两家 LLM，说明其在正式新闻语域和部分政治修辞表达的处理上仍有提升空间。

4.3 各评估维度下的系统表现




Figure 3. Radar chart of performance across five evaluation dimensions.

表 6 各评估维度下四系统均分

维度	DeepL	GPT	Gemini	Claude
Accuracy	4.00	4.56	4.62	4.74

维度	DeepL	GPT	Gemini	Claude
Fluency	4.76	4.84	4.96	4.94
Style	4.08	4.50	4.46	4.68
Terminology	3.92	4.72	4.50	4.64
Cultural Adaptation	3.82	4.42	4.34	4.58

从各维度结果来看，流畅性已经不是主要的区分因素。四个系统在该维度上的得分都很高，差异范围只有 0.20 分，说明生成自然、可读的英文译文已经成为当前机器翻译系统的基本能力。

相比之下，文化适应性和术语准确性更能区分系统差异。文化适应性上，DeepL 和 Claude 之间相差 0.76 分，是五个维度中差距最明显的一个。术语准确性方面，GPT 表现最好，DeepL 相对较弱，这与后文中的具体案例分析基本一致。

Claude 在准确性和风格匹配上都排名第一，说明其在理解原文含义和保持原文表达风格方面表现较为稳定。Gemini 虽然整体均分略低于 GPT 和 Claude，但在流畅性上得分最高，显示出较强的目标语生成能力。

4.4 翻译质量分布热力图




Figure 4. Heatmap of

translation quality scores (50 items × 4 systems).

热力图较直观地展示了 200 条译文的质量分布情况。高分区域主要集中在学术类文本和部分结构较简单的句子上，这说明在标准化、规范化较强的文本中，四个系统的表现都较为稳定。低分区域则主要集中在文化类文本中的 DeepL 列，形成较明显的得分低谷，尤其是涉及歇后语、网络缩写和网络流行语的几个案例。

同时，热力图也显示，即使是整体表现较好的 LLM 系统，在某些特定口语表达上仍然会出现低分点。比如 C03“我要我觉得，不要你觉得”在 Claude 和 GPT 中的得分都不高，说明对于语境依赖很强、带有明显话语权和语用色彩的表达，各系统仍然存在一定困难。

4.5 典型案例分析

案例 1：YYDS 翻译（K06）——DeepL 的事实性错误

表 7 K06 翻译对比

系统	译文	分数
DeepL	"which stands for 'You're the God'"	2.0
GPT	"meaning 'the GOAT' (the greatest of all time)"	5.0
Gemini	"which means 'the GOAT'"	5.0
Claude	"which stands for '永远的神' — meaning 'the GOAT' or 'a legend forever'"	5.0

在这一案例中，DeepL 将“YYDS”错误解释为“You’re the God”，属于较明显的事实性误译。实际上，“YYDS”来源于“永远的神”的拼音首字母。三种 LLM 系统都较准确地识别了这一网络用语的真实含义，并给出了英文中较接近的表达“GOAT”。其中，Claude 不仅保留了原始中文信息，还补充了解释，对目标语读者更加友好。

案例 2：无关言语效应术语（A03）——DeepL 的术语误译

表 8 A03 关键术语对比

系统	关键术语	分数
DeepL	"non-verbal effects" ❌	3.0

系统	关键术语	分数
GPT	"irrelevant speech effect" ✓	5.0
Gemini	"irrelevant speech effect" ✓	5.0
Claude	"irrelevant speech effect" ✓	5.0

“无关言语效应”是心理语言学中的固定术语，对应英文为“irrelevant speech effect”。DeepL 将其误译为“non-verbal effects”，不但术语不准确，语义也发生了偏移。三种 LLM 系统都给出了正确术语，这说明它们在专业术语识别和调用方面具有明显优势。

案例 3：歇后语翻译（K03）——Claude 的多层处理

表 9 K03 翻译对比

系统	译文	分数
DeepL	"A nephew holding a lantern—it still shines on his uncle."	2.4
GPT	"A nephew carrying a lantern—just like before (a pun on 'uncle')."	4.0
Gemini	"Like a nephew carrying a lantern—everything remains the same as always."	3.2
Claude	"A nephew carrying a lantern — same as before (lighting the way for his uncle / business as usual)."	5.0

“外甥打灯笼——照旧（舅）”的难点在于“照旧”和“照舅”的谐音双关。DeepL 基本停留在字面翻译层面，没有传达出其实际含义。Gemini 传递了“照旧”的意思，但双关机制没有体现出来。GPT 注意到了双关，不过解释还不够完整。Claude 则同时保留了字面图像、谐音关系和实际含义，因此得分最高。

案例 4：鲁迅“吃人”（L02）——文学冲击力的保留问题

表 10 L02 关键词对比

系统	关键词	分数
DeepL	"cannibalism"	4.0

系统	关键词	分数
GPT	"eat people"	5.0
Gemini	"Eat people"	5.0
Claude	"cannibalism"	4.0

在鲁迅《狂人日记》中，“吃人”这一表达的力量很大，关键在于其直接性和冲击感。GPT 和 Gemini 使用“eat people”，更接近原文的语言风格，也更能保留文学上的压迫感。相比之下，DeepL 和 Claude 使用“cannibalism”，虽然语义上没有错，但风格上偏书面和抽象，削弱了原文的情绪效果。

案例 5：修辞对仗（K09）——Claude 的表达重构

表 11 K09 翻译对比

系统	译文	分数
DeepL	"Not very hurtful, but extremely insulting."	3.8
GPT	"Not very harmful, but extremely insulting."	3.8
Gemini	"It's not that harmful, but it's highly insulting."	3.8
Claude	"The damage is minimal; the insult is devastating."	5.0

“伤害性不高，侮辱性极强”本身具有鲜明的节奏感和对仗特点。前三个系统虽然大致传达了原意，但句式较平直，未能很好保留原文修辞效果。Claude 通过重新组织表达，在英文中构建出较强的对比关系和语势，因此在这一案例中表现更好。

4.6 错误类型分类统计

表 12 错误类型分类统计

错误类型	出现次数	主要涉及系统	典型案例
术语错误	6	DeepL 为主	A03“无关言语效应”→“non-verbal effects”

错误类型	出现次数	主要涉及系统	典型案例
文化流失	12	DeepL > GPT > Gemini	K03 歇后语双关丢失
语域偏移	5	各家均有	L02“吃人”→“cannibalism”
语义扭曲	3	GPT/Claude	个别句子过度意译
比喻损失	3	DeepL 为主	N06“浪花”比喻丢失
信息增删	2	零星	个别句子添加或省略信息

从错误分布来看，文化流失是出现最多的一类问题，主要集中在 DeepL 上。术语错误也大多出现在 DeepL 的输出中。相比之下，LLM 系统虽然整体表现更好，但也并非完全没有问题，比如在文学表达和强语用句子上仍然会出现语域偏移或过度意译现象。

第五章 讨论

5.1 LLM 的优势：知识储备与语用理解

本研究中，LLM 系统在文化负载型文本和复杂语用表达上的优势比较明显。其原因可能在于，大语言模型在训练过程中接触到大量不同类型文本，因此在文化知识、网络表达和上下文推断方面更有优势。以“YYDS”为例，三种 LLM 都不仅识别了该表达的真实含义，还能找到英文中较接近的文化对应说法，这一点是传统 NMT 系统较难做到的。这种行为与 Guerreiro 等人（2023）关于 NMT 系统幻觉现象的研究发现较为一致。

在口语和反讽表达方面，LLM 也显示出更强的语用理解能力。例如，像“我真是谢谢你了”这类字面上看似礼貌、实际上带有反讽意味的表达，LLM 更容易把握其真正语气，而不是只做字面转译。这说明，除了词汇和句法层面的转换之外，语用层面的理解也在很大程度上影响了翻译质量。

5.2 系统选择与文本类型的关系

研究表明，不同系统的优势并不完全一样。**GPT** 在学术文本上表现最好，说明其在术语处理和逻辑表达方面较稳定。**Gemini** 在口语类文本中得分最高，反映出其在自然口语生成方面具有一定优势。**Claude** 则在文化类和新闻类文本中表现突出，特别是在文化解释和风格控制方面较为稳定。

这也意味着，在实际使用中，翻译工具的选择最好结合文本类型来考虑。若处理的是学术摘要、论文片段等规范性较强的文本，可以优先考虑 **GPT**；若是文化负载内容较多的文本，**Claude** 可能更合适；若以日常表达或口语内容为主，**Gemini** 也具有较强竞争力。**DeepL** 虽然整体分数较低，但在标准化、批量化文本的快速翻译场景中仍有实际价值。

5.3 “简单文本趋同”现象

从结果看，学术类文本整体得分普遍偏高，说明在结构较清晰、术语较固定的句子中，各系统之间已经比较接近。也就是说，对于难度不高、表达规范的文本，当前机器翻译系统普遍能够给出较好的结果，系统差异不会特别明显。

相反，真正能够区分系统质量的，往往是那些具有文化嵌入、修辞效果、强语用色彩或专业术语要求较高的文本。这个现象说明，在今后的机器翻译评估中，仅关注总体均分可能不够，还需要结合具体难点和错误类型分析，才能更准确地判断系统能力。

5.4 流畅性差距缩小，文化处理仍是难点

本研究中，流畅性维度的分差最小，说明“把英文写得通顺”已经不再是当前机器翻译系统最难解决的问题。真正更难的是如何在通顺之外，兼顾文化信息、语域风格和表达效果。

这一点对翻译实践也有启发。对于译后编辑来说，今后的重点可能不应只是改语法、调句子，而应更多放在文化含义、修辞效果和语用适切性上。对于评估研究来说，如果仍然把流畅性作为最核心指标，可能已经不足以有效区分系统能力。

5.5 LLM 的表达重构能力

案例分析中可以看到，部分 LLM 系统已经不只是进行字面对译，而是在一些场合会主动对表达进行重构，以尽量保留原文的语势、修辞或风格。**Claude** 在 K09 中的处理就是比较典型的例子。它没有严格沿用原文句式，而是在英文中重新组织结构，以获得更接近原文效果的表达。

这种做法说明，LLM 在某些情况下已经展现出一定程度的“效果导向”翻译能力。这种能力已经不完全局限于 **Nida**（1964）所说的形式对等或动态对等，而是带有一定创造性重构的特征。它们不仅关注原文说了什么，也在一定程度上尝试考虑原文是怎么说的、读起来是什么感觉。当然，这种重构并不总是成功，有时也可能造成过度意译，因此仍然需要人工判断和把关。

5.6 DeepL 的优势与局限

尽管 DeepL 在本研究中整体排名最后，但它仍有自身优势。首先，DeepL 使用方便、速度快，适合快速获取基础译文。其次，在结构比较清楚、难度相对一般的文本中，DeepL 的译文仍然具有一定可用性。

不过，它的局限也比较明显。第一是术语处理不够稳定，在遇到训练覆盖不足的专业术语时容易出现误译。第二是文化适应能力较弱，对于歇后语、网络流行语、文化典故等内容，往往难以给出较理想的处理结果。因此，如果文本涉及较强文化信息或专业知识，DeepL 的输出更需要人工审校。

5.7 研究局限性

本文也存在一些不足。

第一，本研究的评分由单一评估者完成，难免带有一定主观性。虽然评分过程中进行了记录和复核，但如果后续研究能引入多位评估者，并报告评估者间一致性，结果会更有说服力。

第二，语料规模仍然较小。虽然 50 条语料覆盖了五种文本类型，但每类只有 10 条，难以完全代表该类型内部的全部复杂情况。尤其是学术类文本，目前只涉及部分学科领域，未来还可以扩展到医学、法律、经济等方向。

第三，本文只考察了中译英一个方向。中英之间语言结构和文化差异较大，这可能会放大某些系统差异。今后如果能加入其他语言对，研究结论会更全面。

第四，系统版本会不断更新。本文数据采集于 2025 年 4 月 18 日，因此结果更适合被理解为该时间点上的横向比较，而不是对系统能力的永久性结论。

第五，已有研究指出，提示词设计可以对 LLM 翻译质量产生较明显影响（Peng et al., 2023）。本文采用的是零提示设置，没有对 LLM 进行专门提示优化。这种做法有利于控制变量，但也可能低估了 LLM 在实际翻译场景中的潜力。

第六章 结论

6.1 主要发现

本文基于 50 条中文语料和 200 条译文，对 DeepL、ChatGPT（GPT-4o）、Google Gemini 和 Claude 四种机器翻译系统进行了中译英质量比较。通过五维度人工评估，可以得到以下几点结论。

第一，三种 LLM 系统整体表现都优于 DeepL，其中 Claude 平均得分最高，GPT 和 Gemini 次之。说明在本研究涉及的语料范围内，大语言模型系统在中译英任务上已经表现出比传统 NMT 更强的综合能力。

第二，文本类型对翻译质量影响很大。学术类文本中，各系统表现接近；文化负载类文本中，系统差异最明显。这说明系统质量的真正差距主要体现在高难度文本上。

第三，流畅性已经不再是最核心的区分维度，文化适应性和术语准确性更能体现系统能力。也就是说，当前机器翻译系统普遍能够生成较自然的英文，但在文化转换和专业表达准确性上仍存在明显差异。

第四，各系统都有自己的优势领域。GPT 在学术文本上较强，Gemini 在口语表达上较自然，Claude 在文化负载型文本和风格控制上表现更突出。因此，在实际应用中，应根据文本类型灵活选择系统，而不是依赖单一工具。

第五，部分高级 LLM 已经展现出一定的表达重构能力，能够在目标语中尝试重建原文的修辞效果和表达张力。不过，这种能力并不总是稳定，因此人工审校仍然是必要环节。

6.2 实践建议

基于以上结果，本文提出以下几点建议。

第一，若文本以学术内容为主，可以优先考虑 GPT，其在术语处理和表达准确性方面表现较稳定。

第二，若文本包含较多文化负载信息，如网络流行语、歇后语或典故，Claude 通常更值得优先考虑。

第三，若文本偏口语化，Gemini 在自然表达方面具有一定优势。

第四，若只是对标准化文本进行快速初译，DeepL 仍然可以作为较高效率的工具使用，但后续最好配合人工检查。

第五，无论选用哪一种系统，人工审校都仍然不可缺少，尤其是在文学性、文化性和专业性要求较高的文本中更是如此。

6.3 未来研究展望

后续研究还可以从以下几个方面进一步展开。

第一，扩大语料规模和文本范围，纳入更多学科和更多真实应用场景，以提高研究结果的代表性。

第二，引入多位评估者进行评分，并报告评估者间一致性指标，以增强研究信度。

第三，开展纵向研究，持续追踪不同系统在版本更新后的表现变化。

第四，考察提示词设计对 LLM 翻译质量的影响，比较零提示、少样本提示和角色提示等策略。

第五，将人工评估与自动评估结合起来，探索更高效、更适合中译英任务的综合评估方

法。

第六，进一步研究多系统协同翻译的可能性，看不同系统是否能够通过组合方式提升整体译文质量。

参考文献

Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. In Proceedings of the 3rd International Conference on Learning Representations (ICLR 2015).

Banerjee, S., & Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. In Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization (pp. 65–72).

Brown, P. F., Cocke, J., Della Pietra, S. A., Della Pietra, V. J., Jelinek, F., Lafferty, J. D., Mercer, R. L., & Roossin, P. S. (1990). A statistical approach to machine translation. *Computational Linguistics*, 16(2), 79–85.

Graham, Y., Baldwin, T., Moffat, A., & Zobel, J. (2013). Continuous measurement scales in human evaluation of machine translation. In Proceedings of the 7th Linguistic Annotation Workshop and Interoperability with Discourse (pp. 33–41).

Guerreiro, N. M., Voita, E., & Martins, A. F. T. (2023). Looking for a needle in a haystack: A comprehensive study of hallucinations in neural machine translation. In Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2023) (pp. 1059–1075).

Hendy, A., Abdelrehim, M., Sharaf, A., Raunak, V., Gabr, M., Matsushita, H., Kim, Y. J., Afify, M., & Awadalla, H. H. (2023). How good are GPT models at machine translation? A comprehensive evaluation. *arXiv preprint arXiv:2302.09210*.

Jiao, W., Wang, W., Huang, J., Wang, X., & Tu, Z. (2023). Is ChatGPT a good translator? A preliminary study. *arXiv preprint arXiv:2301.08745*.

Lommel, A., Uszkoreit, H., & Burchardt, A. (2014). Multidimensional quality metrics (MQM): A framework for declaring and describing translation quality metrics. *Tradumàtica*, 12, 455–463.

Nida, E. A. (1964). *Toward a Science of Translating: With Special Reference to Principles and Procedures Involved in Bible Translating*. Leiden: Brill.

- Papineni, K., Roukos, S., Ward, T., & Zhu, W. J. (2002). BLEU: A method for automatic evaluation of machine translation. In Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL 2002) (pp. 311–318).
- Peng, K., Ding, L., Zhong, Q., Shen, L., Liu, X., Zhang, M., Ouyang, Y., & Tao, D. (2023). Towards making the most of ChatGPT for machine translation. In Findings of the Association for Computational Linguistics: EMNLP 2023 (pp. 5622–5633).
- Rei, R., Stewart, C., Farinha, A. C., & Lavie, A. (2020). COMET: A neural framework for MT evaluation. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020) (pp. 2685–2702).
- Reiss, K. (1971). Möglichkeiten und Grenzen der Übersetzungskritik. Munich: Hueber.
- Reiss, K. (1976). Texttyp und Übersetzungsmethode: Der operative Text. Kronberg: Scriptor.
- Snoover, M., Dorr, B., Schwartz, R., Micciulla, L., & Makhoul, J. (2006). A study of translation edit rate with targeted human annotation. In Proceedings of the 7th Conference of the Association for Machine Translation in the Americas (AMTA 2006) (pp. 223–231).
- Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. In Advances in Neural Information Processing Systems 27 (NeurIPS 2014) (pp. 3104–3112).
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems 30 (NeurIPS 2017) (pp. 5998–6008).
- Venuti, L. (1995). The Translator's Invisibility: A History of Translation. London: Routledge.
-

附录

附录 A: 50 条中文原文语料完整表（见表 1）

附录 B: 200 条翻译输出及评分数据完整表（见 Excel 文件 LLM_Translation_Evaluation.xlsx）

附录 C: 四张数据可视化图表（fig1_overall.png, fig2_by_type.png, fig3_radar.png, fig4_heatmap.png）